



การวิเคราะห์ความรู้สึกเชิงแง่มุมพร้อมการแสดงผลด้วยรหัสสี

โดย

นางสาว สุชานาถ หันทยุง

โครงการพิเศษนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

วิทยาศาสตร์บัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์

ปีการศึกษา 2567

ลิขสิทธิ์ของมหาวิทยาลัยธรรมศาสตร์

การวิเคราะห์ความรู้สึกเชิงแง่มุมพร้อมการแสดงผลด้วยรหัสสี

โดย

นางสาว สุชานาถ หันทยุง

โครงการพิเศษนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร

วิทยาศาสตร์บัณฑิต

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์และเทคโนโลยี มหาวิทยาลัยธรรมศาสตร์

ปีการศึกษา 2567

ลิขสิทธิ์ของมหาวิทยาลัยธรรมศาสตร์

ASPECT BASED SENTIMENTAL ANALYSIS WITH COLOR CODED
VISUALIZATION

BY

MISS SUCHANAT HANTHYUNG

A FINAL-YEAR PROJECT REPORT SUBMITTED IN PARTIAL FULFILLMENT
OF THE REQUIREMENTS FOR THE DEGREE OF BACHELOR OF SCIENCE
COMPUTER SCIENCE

FACULTY OF SCIENCE AND TECHNOLOGY

THAMMASAT UNIVERSITY

ACADEMIC YEAR 2024

COPYRIGHT OF THAMMASAT UNIVERSITY

มหาวิทยาลัยธรรมศาสตร์
คณะวิทยาศาสตร์และเทคโนโลยี

รายงานโครงการพิเศษ

ของ

นางสาว สุชานาถ หันทุยง

เรื่อง

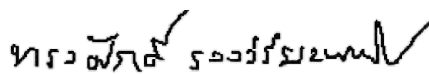
การวิเคราะห์ความรู้สึกเชิงแง่มุมพร้อมการแสดงผลด้วยรหัสสี
ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
เมื่อ วันที่ 30 พฤษภาคม พ.ศ. 2568

อาจารย์ที่ปรึกษา



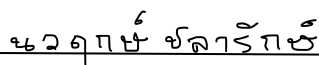
(ผศ. ดร. ปกป้อง ส่องเมือง)

กรรมการสอบโครงการพิเศษ



(ผศ. ดร. ทรงศักดิ์ รongwiriyanon)

กรรมการสอบโครงการพิเศษ



(อ. ดร. นวฤกษ์ ชลารักษ์)

มหาวิทยาลัยธรรมศาสตร์
คณะวิทยาศาสตร์และเทคโนโลยี

รายงานโครงงานพิเศษ


ของ

นางสาว สุชานาถ หันทยุง

เรื่อง

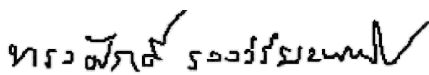
การวิเคราะห์ความรู้สึกเชิงแง่มุมพร้อมการแสดงผลด้วยรหัสสี
ได้รับการตรวจสอบและอนุมัติ ให้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตร
หลักสูตรวิทยาศาสตรบัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์
เมื่อ วันที่ 30 พฤษภาคม พ.ศ. 2568

อาจารย์ที่ปรึกษา



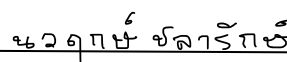
(ผศ. ดร. ปกป้อง ส่องเมือง)

กรรมการสอบโครงงานพิเศษ



(ผศ. ดร. ทรงศักดิ์ ร่องวิริยะพานิช)

กรรมการสอบโครงงานพิเศษ



(อ. ดร. นวฤทธิ์ ชลารักษ์)

หัวข้อโครงการพิเศษ

การวิเคราะห์ความรู้สึกเชิงแง่มุมพร้อมการแสดงผลด้วย
รหัสสี

ชื่อผู้เขียน

นางสาวสุชานาถ หันทยุง

ชื่อปริญญา

วิทยาศาสตร์บัณฑิต สาขาวิชาวิทยาการคอมพิวเตอร์

สาขาวิชา/คณะ/มหาวิทยาลัย

สาขาวิชาวิทยาการคอมพิวเตอร์

คณะวิทยาศาสตร์และเทคโนโลยี

มหาวิทยาลัยธรรมศาสตร์

อาจารย์ที่ปรึกษาโครงการพิเศษ

ผศ. ดร. ปกป้อง ส่องเมือง

ปีการศึกษา

2567

บทคัดย่อ

งานวิจัยนี้มุ่งเน้นการพัฒนาและเปรียบเทียบโมเดลการวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) สำหรับข้อความรีวิวภาษาอังกฤษ โดยนำเสนอการวิเคราะห์และประยุกต์ใช้โมเดลจากสามยุคที่แตกต่างกัน ได้แก่ TF-IDF ร่วมกับ Support Vector Machine (SVM), Word2vec ร่วมกับ Long Short-Term Memory (LSTM), และ Fine-tuned BERT โมเดลเหล่านี้ถูกนำมาใช้ทั้งสำหรับการจำแนกแง่มุม (Aspect Classification) ซึ่งเป็นงาน Multi-label และการจำแนกความรู้สึก (Sentiment Classification) ซึ่งเป็นงาน Multi-class เพื่อให้ได้ผลลัพธ์การวิเคราะห์ที่ละเอียดอ่อนยิ่งขึ้น

การศึกษานี้ครอบคลุมถึงแนวคิดทางทฤษฎีเบื้องหลังของแต่ละโมเดล รวมถึงรายละเอียดเฉพาะในการฝึกโมเดลยุคแรก ๆ เช่น การประยุกต์ใช้ MultiLabelBinarizer() กับ OneVsRestClassifier() สำหรับ TF-IDF + SVM สำหรับโมเดล Word2vec + LSTM ได้มีการใช้ Word Embeddings ที่ผ่านการ Pre-train มาแล้วจาก GoogleNews-vectors-negative300.bin สำหรับโมเดล Fine-tuned BERT ได้มีการอธิบายถึงกระบวนการ Tokenization เฉพาะของ BERT และการ Fine-tuning โมเดล bert-base-uncased ที่ผ่านการ Pre-train มาแล้ว.

ผลการทดลองแสดงให้เห็นว่าโมเดล Fine-tuned BERT มีประสิทธิภาพที่เหนือกว่าโมเดลอื่นๆ อย่างชัดเจนในเกือบทุกแง่มุมและทุกประเภทความรู้สึก ทั้งในด้าน Accuracy และ F1-score ซึ่งสะท้อนถึงความสามารถในการเข้าใจบริบทที่ลึกซึ้งของโมเดล นอกจากนี้ รายงานยังได้อธิบายวิธีการแสดงผลลัพธ์ ABSA ด้วยรหัสสี ซึ่งช่วยให้ผู้ใช้สามารถเข้าใจและตีความผลการวิเคราะห์ได้อย่างชัดเจนยิ่งขึ้น

คำสำคัญ: การวิเคราะห์ความรู้สึกเชิงแง่มุม, TF-IDF, SVM, Word2vec, LSTM, BERT, การแสดงผลด้วยรหัสสี

Thesis Title	ASPECT BASED SENTIMENTAL ANALYSIS WITH COLOR CODED VISUALIZATION
Author	Suchanat Hanthayung
Degree	Bachelor of Science
Major Field/Faculty/University	Computer Science Faculty of Science and Technology Thammasat University
Project Advisor	Asst. Prof. Pokpong Songmuang, Ph.D.
Academic Years	2024

ABSTRACT

This research focuses on the development and comparison of Aspect-Based Sentiment Analysis (ABSA) models for English text reviews. It presents an analysis and application of models from three different generations: TF-IDF combined with Support Vector Machine (SVM), Word2vec combined with Long Short-Term Memory (LSTM), and Fine-tuned BERT. These models are employed for both Aspect Classification, which is a multi-label task, and Sentiment Classification, which is a multi-class task, to achieve more granular analytical results.

The study covers the theoretical concepts underpinning each model, including specific details on training earlier generation models. For instance, it details the application of `MultiLabelBinarizer()` with `OneVsRestClassifier()` for TF-IDF + SVM. For the Word2vec + LSTM model, pre-trained Word Embeddings from `GoogleNews-vectors-negative300.bin` were utilized, with the Embedding Layer being frozen to leverage the pre-learned knowledge. For the Fine-tuned BERT model, the report explains the BERT-specific Tokenization process and the fine-tuning of the pre-trained `bert-base-uncased` model.

Experimental results demonstrate that the Fine-tuned BERT model exhibits superior performance compared to the other models across almost all aspects and sentiment categories, in terms of both Accuracy and F1-score. This superiority reflects the model's deep contextual understanding capabilities. Furthermore, the report describes a method for color-coded visualization of ABSA results, which enables users to clearly understand and interpret the analysis.

Keywords: Aspect-Based Sentiment Analysis, TF-IDF, SVM, Word2vec, LSTM, BERT, Color-coded Visualization

กิตติกรรมประกาศ

ขอขอบคุณทุกคนที่เข้ามามีส่วนร่วมไม่ว่าจะทางตรงทางอ้อมต่องานชิ้นนี้และอาจารย์ที่ให้คำปรึกษาและคำแนะนำที่ผลักดันจนได้ผลงานวิจัยชิ้นนี้ออกมา

นางสาวสุชานาถ หันทุยง

สารบัญ

หน้า

บทคัดย่อ	(1)
ABSTRACT	(3)
กิตติกรรมประกาศ	(4)
สารบัญ	(5)
สารบัญตาราง	(8)
สารบัญภาพ	(9)
รายการสัญลักษณ์และคำย่อ	(10)
บทที่ 1 บทนำ	1
1.1 ความเป็นมาและความสำคัญของโครงการ	1
1.2 วัตถุประสงค์	1
1.3 ขอบเขตของโครงการ	2
1.4 ประโยชน์ของโครงการ	2
1.5 ข้อจำกัดของโครงการ	2
บทที่ 2 วรรณกรรมและงานวิจัยที่เกี่ยวข้อง	3
2.1 แนวคิดทฤษฎีที่เกี่ยวข้อง	3
2.1.1 การวิเคราะห์ความรู้สึกเชิงแง่มุม	3
2.1.2 Term Frequency-Inverse Document Frequency (TF-IDF)	3
2.1.3 Support Vector Machine (SVM)	4
2.1.4 Word2vec	5

	(7)
2.1.5 Long Short-Term Memory (LSTM)	6
2.1.6 Bidirectional Encoder Representations from Transformers (BERT)	7
2.2 งานวิจัยที่เกี่ยวข้อง	8
2.2.1 การวิเคราะห์ความรู้สึกเชิงแง่มุมด้วย TF-IDF และ SVM	8
2.2.2 การวิเคราะห์ความรู้สึกเชิงแง่มุมด้วย Word2vec และ LSTM	8
2.2.3 การวิเคราะห์ความรู้สึกเชิงแง่มุมด้วย Fine-tuned BERT	9
บทที่ 3 วิธีการวิจัย	10
3.1 ภาพรวมของโครงการ	10
3.2 การวิเคราะห์ขอบเขตและความต้องการของระบบ	10
3.3 การดำเนินงาน	10
3.3.1 การรวบรวมและเตรียมข้อมูล	10
3.3.2 การสร้างและฝึกฝนโมเดล	11
3.4 ประเมินผลโมเดล	14
3.5 การนำเสนอการแสดงผลด้วยสี	14
บทที่ 4 ผลการดำเนินงาน	16
4.1 ผลการทดลอง	16
บทที่ 5 สรุป	18
5.1 บทสรุป	18
5.2 ข้อจำกัดของการวิจัย	18
5.3 ข้อเสนอแนะสำหรับงานวิจัยในอนาคต	19
รายการอ้างอิง	20

สารบัญตาราง

หน้า

ตารางที่ 4.1 ผลการทดลอง aspect classification	16
ตารางที่ 4.4 ผลการทดลอง sentiment classification	16

สารบัญภาพ

	หน้า
ภาพที่ 2.1 สูตรการทำงานของ TF หรือ Term Frequency	4
ภาพที่ 2.2 สูตรการทำงานของ IDF หรือ Inverse Document Frequency	4
ภาพที่ 2.3 สถาปัตยกรรมของ LSTM	6
ภาพที่ 2.4 แสดงสถาปัตยกรรมของโมเดล BERTbase-uncase	7
ภาพที่ 3.1 pipeline การนำเสนอการแสดงผลด้วยสี	11
ภาพที่ 4.1 UI ของ หน้าแสดงผลลัพธ์การแสดงผลด้วยสี	17
ภาพที่ 4.2 ตัวอย่างการทดลองทดสอบการทำงาน	17

รายการสัญลักษณ์และคำย่อ

สัญลักษณ์/คำย่อ	คำเต็ม/คำจำกัดความ
ABSA	Aspect-Based Sentiment Analysis
AI	Artificial Intelligence
BERT	Bidirectional Encoder Representations from Transformers
CBOW	Continuous Bag of Words
LSTM	Long Short-Term Memory
NLP	Natural Language Processing
RNN	Recurrent Neural Network
SVM	Support Vector Machine
TF	Term Frequency
IDF	Inverse Document Frequency
TF-IDF	Term Frequency-Inverse Document Frequency

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของโครงการ

ในยุคปัจจุบันที่ข้อมูลดิจิทัลมีปริมาณมหาศาล การทำความเข้าใจความคิดเห็นและความรู้สึกของผู้คนที่ติดต่อผลิตภัณฑ์ บริการ หรือประเด็นต่าง ๆ กลายเป็นสิ่งสำคัญในการตัดสินใจทางธุรกิจและการวิจัยทางสังคม การวิเคราะห์ความรู้สึก (Sentiment Analysis) เป็นสาขาหนึ่งของกระบวนการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ที่มุ่งเน้นการระบุและจำแนกอารมณ์หรือทัศนคติของผู้คนที่แสดงออกมาในข้อความเพื่อให้มองเห็นว่าผู้คนมีปฏิกิริยาต่อสิ่งหนึ่งสิ่งใดเช่นไร อย่างไรก็ตาม การวิเคราะห์ความรู้สึกแบบดั้งเดิมนั้นมักให้ผลลัพธ์ในระดับภาพรวมของข้อความ ซึ่งอาจไม่เพียงพอต่อการทำความเข้าใจในรายละเอียดปลีกย่อยของความคิดเห็น ตัวอย่างเช่น ประโยคที่กล่าวถึง “อาหารอร่อยแต่บริการช้า” หากวิเคราะห์โดยรวมอาจให้ผลลัพธ์เป็นกลาง แต่ในความเป็นจริงแล้วมีทั้งแง่มุมที่ดี (อาหาร) และแง่มุมที่ไม่ดี (บริการ)

ในการแก้ไขข้อจำกัดนี้เอง การวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) จึงได้รับความนิยมอย่างมาก เนื่องจากความสามารถในการระบุและวิเคราะห์ความรู้สึกที่เกี่ยวข้องกับแง่มุมหรือคุณลักษณะเฉพาะของสิ่งต่าง ๆ ได้อย่างละเอียด ฉะนั้น ABSA จึงเป็นเครื่องมือที่มีประสิทธิภาพในการให้ข้อมูลเชิงลึกที่แม่นยำยิ่งขึ้นเกี่ยวกับความคิดเห็นของลูกค้า การตรวจสอบสื่อสังคมออนไลน์ และการบริการลูกค้า การนำเสนอผลลัพธ์ในรูปแบบที่เข้าใจง่าย เช่น การแสดงผลด้วยรหัสสียิ่งช่วยเพิ่มประโยชน์ในการตีความข้อมูลเชิงลึกเหล่านี้

1.2 วัตถุประสงค์

1. ศึกษาและอธิบายแนวคิดทฤษฎี ทำความเข้าใจหลักการพื้นฐานและวิวัฒนาการของโมเดล ABSA ใน 3 ยุค ได้แก่ TF-IDF + SVM, Word2vec + LSTM และ BERT
2. พัฒนาและเปรียบเทียบการประยุกต์ใช้โมเดล Aspect Classification และ Sentiment Classification เพื่อแสดงให้เห็นถึงรายละเอียดทางเทคนิคในการนำโมเดลแต่ละประเภทไปใช้ในการจำแนกแง่มุมและจำแนกรู้สึก
3. นำเสนอแนวทางการแสดงผลการวิเคราะห์ด้วยสี เพื่ออำนวยความสะดวกในการทำทำความเข้าใจและตีความผลลัพธ์ของ ABSA ให้ชัดเจนยิ่งขึ้น

4. เพื่ออธิบายวิธีการทำงานของโค้ด Python สำหรับโมเดล Aspect Classification ของ BERT และกระบวนการสร้างชุดข้อมูล Term สำหรับการแสดงผลด้วยรหัสสี

1.3 ขอบเขตของโครงการ

1. ใช้ benchmark dataset ข้อมูลรีวิวร้านอาหารที่เป็นภาษาอังกฤษ
2. การฝึกฝนจะครอบคลุมสองงานหลักคือ Aspect Classification (Multi-label) และ Sentiment Classification (Multi-class)
3. สำหรับ Word2Vec + LSTM จะใช้ Word Embeddings ที่ผ่านการ Pre-train มาแล้ว (GoogleNews-vectors-negative300.bin) และสำหรับ BERT จะ Fine-tune โมเดล bert-base-uncased ที่ผ่านการ Pre-train มาแล้ว
4. ประเมินประสิทธิภาพของโมเดลผ่านค่า Accuracy, F1-score

1.4 ประโยชน์ของโครงการ

1. สร้างความเข้าใจเชิงลึกเกี่ยวกับวิวัฒนาการของโมเดล ABSA ตั้งแต่เทคนิคพื้นฐานไปจนถึงโมเดลโครงข่ายประสาทเทียมเชิงลึกและโมเดล Transformer
2. เป็นแนวทางและเอกสารอ้างอิงสำหรับนักวิจัยหรือผู้ที่สนใจในการประยุกต์ใช้เทคนิค ABSA สำหรับงานวิเคราะห์ข้อความ
3. ช่วยในการตัดสินใจเลือกโมเดลที่เหมาะสมสำหรับงาน ABSA โดยพิจารณาจากข้อดีข้อเสียและลักษณะการทำงานของแต่ละโมเดล
4. นำเสนอแนวคิดในการแสดงผลผลลัพธ์ ABSA ด้วยรหัสสี ซึ่งช่วยเพิ่มความสามารถในการตีความข้อมูลเชิงลึก

1.5 ข้อจำกัดของโครงการ

1. จำนวนข้อมูลที่ติดป้ายกำกับมีจำกัด ชุดข้อมูลรีวิวที่ใช้อาจมีจำนวนไม่มากพอที่จะครอบคลุมความหลากหลายของรูปแบบภาษาและบริบททั้งหมดที่ปรากฏในรีวิวร้านอาหาร
2. ข้อจำกัดในการจัดการความหลากหลายของภาษาธรรมชาติ การใช้สำนวน (idioms), คำสแลง (slang), หรือรูปแบบการเขียนที่ไม่เป็นทางการ
3. การพึ่งพา Pre-trained Embeddings และโมเดล BERT ที่ผ่านการ Pre-train

บทที่ 2

วรรณกรรมและงานวิจัยที่เกี่ยวข้อง

การวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) เป็นสาขาที่สำคัญในการประมวลผลภาษาธรรมชาติ ซึ่งมีวิวัฒนาการของเทคนิคและโมเดลที่หลากหลาย เพื่อให้สามารถระบุและวิเคราะห์ความรู้สึกที่เกี่ยวข้องกับแง่มุมเฉพาะของข้อความได้อย่างละเอียด บทนี้จะนำเสนอแนวคิดทฤษฎีพื้นฐานของโมเดลที่ใช้ในการวิจัยนี้ รวมถึงงานวิจัยที่เกี่ยวข้องที่ได้นำโมเดลเหล่านี้ไปประยุกต์ใช้ในบริบทของ ABSA

2.1 แนวคิดทฤษฎีที่เกี่ยวข้อง

2.1.1 การวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA)

ในขณะที่การวิเคราะห์ความรู้สึกแบบทั่วไปจะให้ผลลัพธ์ความรู้สึกรวมของข้อความทั้งหมด ABSA จะแยกแยะความรู้สึกสำหรับแต่ละแง่มุมที่ปรากฏ ตัวอย่างเช่น ในประโยค "อาหารอร่อยแต่การบริการช้า" ABSA จะสามารถระบุได้ว่าความรู้สึกต่อ "อาหาร" เป็นบวก และความรู้สึกต่อ "การบริการ" เป็นลบ ซึ่งสะท้อนความซับซ้อนของความคิดเห็นในโลกแห่งความเป็นจริงได้ดีกว่าองค์ประกอบหลักของ ABSA มักประกอบด้วยสามขั้นตอน ได้แก่ การสกัดแง่มุม (Aspect Term Extraction) ซึ่งเป็นการระบุคำหรือวลีที่เป็นตัวแทนของแง่มุม, การจำแนกแง่มุม (Aspect Classification) ซึ่งเป็นการจัดหมวดหมู่แง่มุมที่สกัดได้ และการจำแนกความรู้สึก (Sentiment Classification) ซึ่งเป็นการกำหนดขั้วความรู้สึกสำหรับแต่ละแง่มุม การวิจัยนี้มุ่งเน้นที่โมเดลสำหรับการจำแนกแง่มุมและการจำแนกความรู้สึก ซึ่งเป็นส่วนสำคัญในการทำความเข้าใจความคิดเห็นเชิงลึก

2.1.2 Term Frequency-Inverse Document Frequency (TF-IDF)

TF-IDF (Term Frequency-Inverse Document Frequency) ถือเป็นเทคนิคพื้นฐานและทรงพลังในด้านการทำเหมืองข้อความ (text mining) และการดึงข้อมูล (information retrieval) ที่ช่วยระบุความสำคัญของคำในแต่ละเอกสารอย่างมีประสิทธิภาพ หลักการของ TF-IDF คือการให้ค่าสูงกับคำที่ปรากฏบ่อยในเอกสารหนึ่งแต่ไม่ปรากฏบ่อยในเอกสารอื่น ๆ ซึ่งเป็นตัวบ่งชี้ว่าคำนั้นมีความเฉพาะเจาะจงและเกี่ยวข้องกับเนื้อหาของเอกสารเป้าหมาย เทคนิคนี้มักถูกใช้ในการจัดอันดับเอกสาร, การสร้างแท็ก, การจำแนกประเภทข้อความ, และการดึงข้อมูลโดยอิงจากคำค้นหา (Shahzad Qaiser and Ramsha, 2018)

- **Term Frequency (TF):** คือความถี่ที่คำหนึ่งๆ ปรากฏในเอกสารหนึ่งๆ การคำนวณ TF อาจเป็นแบบไบนารี (1 ถ้าคำปรากฏ, 0 ถ้าไม่ปรากฏ) หรือนับจำนวนครั้งที่คำปรากฏ

$$TF(\text{ของคำคำหนึ่ง}) = \frac{\text{จำนวนของคำนั้นๆ ในเอกสาร}}{\text{จำนวนของคำทั้งหมดในเอกสาร}}$$

ภาพที่ 2.1 สูตรการทำงานของ TF หรือ Term Frequency

- **Inverse Document Frequency (IDF):** คือค่าที่สะท้อนความหายากของคำนั้นๆ ในชุดเอกสารทั้งหมด คำที่ปรากฏในเอกสารจำนวนน้อยจะมีค่า IDF สูงบ่งชี้ว่าคำนั้นมีความเฉพาะเจาะจงและมีความสำคัญต่อเอกสารที่ปรากฏมากกว่าคำที่ปรากฏบ่อยในหลายเอกสาร IDF คำนวณโดยใช้ลอการิทึมของอัตราส่วนระหว่างจำนวนเอกสารทั้งหมดกับจำนวนเอกสารที่มีคำนั้นๆ

$$IDF(\text{ของคำคำหนึ่ง}) = \log\left(\frac{\text{จำนวนเอกสารทั้งหมดที่ใช้พิจารณา}}{\text{จำนวนเอกสารที่มีคำคำนั้นปรากฏอยู่}}\right)$$

ภาพที่ 2.1 สูตรการทำงานของ IDF หรือ Inverse Document Frequency

ข้อดีของ TF-IDF คือความเรียบง่าย ความสามารถในการปรับใช้กับภาษาใดก็ได้ และไม่ต้องใช้ข้อมูลป้ายกำกับ (unsupervised-friendly) ทำให้เหมาะสมกับงานเบื้องต้นก่อนการประยุกต์ใช้โมเดลขั้นสูง แต่ข้อจำกัดคือ TF-IDF ไม่สามารถเข้าใจความหมายเชิงบริบทของคำ

2.1.3. Support Vector Machine (SVM)

Support Vector Machine (SVM) เป็นอัลกอริทึมการเรียนรู้ภายใต้การกำกับที่พัฒนาขึ้นโดย Vapnik โดยมีพื้นฐานจากทฤษฎีการเรียนรู้เชิงสถิติ (Statistical Learning Theory) ซึ่งเน้นการลดความเสี่ยงเชิงโครงสร้าง (Structural Risk Minimization) และใช้แนวคิดในการสร้างเส้นไฮเปอร์เพลน (Hyperplane) ที่สามารถแยกข้อมูลระหว่างคลาสบวกและลบได้ดีที่สุด โดยพิจารณาจากตำแหน่งของตัวอย่างที่เป็น Support Vectors เพื่อให้ได้ระยะห่าง (margin) ระหว่างคลาสสูงสุด และลดความเสี่ยงโดยรวมของแบบจำลอง (Di FU, Bo ZHOU, and Jinglu HU, 2015)

จากงานวิจัยของ Vapnik (1999) สามารถบอกได้ว่า Support Vector Machine (SVM) เป็นอัลกอริทึมที่มีประสิทธิภาพสูงในการจัดการกับชุดข้อมูลที่มีมิติสูงและมีความซับซ้อน โดยเฉพาะในกรณีที่ข้อมูลไม่สามารถจำแนกได้อย่างชัดเจนในรูปแบบเชิงเส้น SVM มีความสามารถในการแปลงปัญหาที่ซับซ้อนให้อยู่ในรูปแบบที่สามารถจำแนกได้ชัดเจนมากขึ้นในมิติที่เหมาะสม พร้อมทั้งควบคุมความสามารถในการจำแนกข้อมูลใหม่ได้ดีหรือที่เรียกว่า “generalization” ซึ่งเป็นปัจจัยสำคัญในการหลีกเลี่ยงการเกิด overfitting โดยเฉพาะอย่างยิ่งในกรณีที่จำนวนข้อมูลฝึกสอนจำกัด จุดแข็งของ SVM ยังอยู่ที่การเลือกใช้ข้อมูลเพียงบางส่วนที่สำคัญที่สุดในการตัดสินใจ ซึ่งช่วยลดความซับซ้อนของแบบจำลองและเพิ่มประสิทธิภาพในการเรียนรู้

2.1.4. Word2vec

Word2vec เป็นชุดของโมเดลโครงข่ายประสาทเทียมที่ปฏิวัติวงการประมวลผลภาษาธรรมชาติ โดยสามารถเรียนรู้การสร้างเวกเตอร์แทนคำ (word embeddings) ซึ่งเป็นตัวแทนคำในรูปแบบเวกเตอร์ต่อเนื่องที่สามารถจับความหมายและความสัมพันธ์เชิงความหมายระหว่างคำได้ โมเดล Word2vec มีสองสถาปัตยกรรมหลัก

- **Continuous Bag of Words (CBOW):** โมเดลนี้คาดการณ์คำเป้าหมายจากบริบทของคำรอบข้าง
- **Skip-Gram:** โมเดลนี้ใช้คำเป้าหมายปัจจุบันเพื่อคาดการณ์คำบริบทที่อยู่รอบๆ Skip-Gram มักจะให้ผลลัพธ์ที่ดีกว่าสำหรับคำที่ปรากฏไม่บ่อยนัก

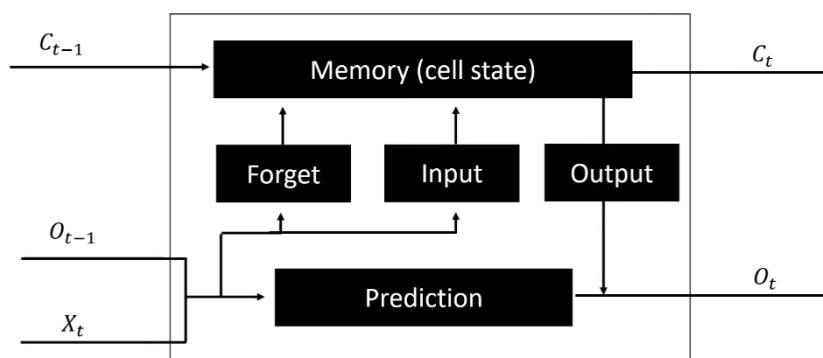
การฝึกโมเดล Word2vec บนคลังข้อความขนาดใหญ่จะช่วยให้เวกเตอร์คำที่ได้สามารถสะท้อนความสัมพันธ์เชิงความหมายและไวยากรณ์ของคำได้ ตัวอย่างเช่น เวกเตอร์ของ "king" ลบด้วยเวกเตอร์ของ "man" บวกด้วยเวกเตอร์ของ "woman" อาจได้ผลลัพธ์ใกล้เคียงกับเวกเตอร์ของ "queen" การฝึก Word2vec มักใช้เทคนิคการประมาณค่าเพื่อลดภาระการคำนวณ เช่น Hierarchical Softmax และ Negative Sampling

Negative Sampling เป็นเทคนิคที่สำคัญที่ช่วยลดภาระการคำนวณในการฝึก Word2vec โดยเฉพาะโมเดล Skip-Gram แทนที่จะคำนวณการกระจายความน่าจะเป็นทั้งหมดของคำศัพท์ (ซึ่งมีขนาดใหญ่มาก) Negative Sampling จะเปลี่ยนเป้าหมายการฝึกเป็นการแยกแยะคำเป้าหมายออกจากคำ “เสียรบกวน” (negative words) เพียงไม่กี่คำ สำหรับแต่ละคู่คำ-บริบท (target word และ context word) โมเดลจะประมวลผลไม่เพียงแต่คำบริบทจริง ช่วยลดการอัปเดตน้ำหนักสำหรับคำทั้งหมดในคลังคำศัพท์ ทำให้การคำนวณมีประสิทธิภาพมากขึ้นอย่างมาก

GoogleNews-vectors-negative300.bin: ไฟล์ GoogleNews-vectors-negative300.bin เป็นโมเดลเวกเตอร์คำที่ถูกฝึกมาล่วงหน้าโดย Google ไฟล์ไบนารีขนาดใหญ่นี้ประกอบด้วยชุดเวกเตอร์คำ ซึ่งแต่ละคำหรือวลีจะถูกแทนด้วยเวกเตอร์ตัวเลขในพื้นที่ 300 มิติ โมเดลนี้ถูกฝึกจากคลังข้อความขนาดใหญ่ที่มาจากบทความข่าวและข้อความบนเว็บ ทำให้สามารถจับความหมายและความสัมพันธ์เชิงความหมายระหว่างคำได้อย่างมีประสิทธิภาพ การใช้โมเดลที่ฝึกมาล่วงหน้าเช่นนี้ช่วยให้สามารถนำเวกเตอร์คำที่มีคุณภาพสูงไปใช้ในงาน NLP ได้โดยไม่ต้องเสียเวลาและทรัพยากรในการฝึกโมเดล Word2vec ด้วยตนเอง

2.1.5 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) เป็นโครงข่ายประสาทเทียมแบบวนซ้ำ (Recurrent Neural Network: RNN) ชนิดหนึ่งที่ออกแบบมาเพื่อแก้ไขปัญหา vanishing gradient และ exploding gradient ที่มักพบใน RNN แบบมาตรฐาน ปัญหาเหล่านี้ทำให้ RNN ทั่วไปไม่สามารถเรียนรู้ความสัมพันธ์ระยะยาวในข้อมูลลำดับได้ ดังนั้น LSTM มีความสามารถในการจดจำข้อมูลเป็นระยะเวลานานขึ้น และสามารถคาดการณ์ตามแนวโน้มในอดีตของข้อมูลได้



ภาพที่ 2.3 สถาปัตยกรรมของ LSTM

สถาปัตยกรรมของ LSTM ประกอบด้วย "เซลล์" (cell) และ "เกต" (gates) สามประเภท ได้แก่ input gate, forget gate และ output gate เกตเหล่านี้ทำหน้าที่ควบคุมการไหลของข้อมูลเข้าและออกจากเซลล์ และตัดสินใจว่าจะเก็บข้อมูลใดไว้และจะทิ้งข้อมูลใดทิ้งไป


- **Forget Gate:** ตัดสินใจว่าจะทิ้งข้อมูลใดจากสถานะก่อนหน้า โดยแปลงสถานะก่อนหน้าและอินพุตปัจจุบันให้เป็นค่าระหว่าง 0 ถึง 1 ค่า 1 หมายถึงการเก็บข้อมูลไว้ทั้งหมด และค่า 0 หมายถึงการทิ้งข้อมูลทั้งหมด
- **Input Gate:** ตัดสินใจว่าจะเก็บข้อมูลใหม่ส่วนใดไว้ในสถานะเซลล์ปัจจุบัน

- **Output Gate:** ควบคุมว่าจะส่งข้อมูลส่วนใดจากสถานะเซลล์ปัจจุบันออกไปเป็นผลลัพธ์

การทำงานของเกตเหล่านี้ช่วยให้ LSTM สามารถเรียนรู้ที่จะจดจำหรือลืมข้อมูลได้อย่างเลือกสรรตามความสำคัญ ทำให้สามารถจัดการกับความสัมพันธ์ระยะยาวในลำดับข้อมูลได้อย่างมีประสิทธิภาพ LSTM มีความได้เปรียบเหนือ RNN อื่น ๆ และวิธีการเรียนรู้ลำดับอื่น ๆ เนื่องจากความไม่ไวต่อความยาวของช่องว่างในข้อมูล

2.1.6 Bidirectional Encoder Representations from Transformers (BERT)

Bidirectional Encoder Representations from Transformers (BERT) เป็นโมเดลภาษาที่ถูกรวบรวมโดยนักวิจัยจาก Google ในปี 2018 โดยเป็นโมเดลการเรียนรู้ภาษาธรรมชาติที่ได้รับความนิยมอย่างแพร่หลาย เนื่องจากความสามารถในการสร้างบริบทของคำแบบสองทิศทางโดยอาศัยสถาปัตยกรรมของ Transformer ซึ่งแตกต่างจากโมเดลก่อนหน้านี้ โดย BERT ทำการฝึกโมเดลด้วยวิธีการ pre-training บนคลังข้อมูลขนาดใหญ่ (corpus) และสามารถนำไป fine-tune สำหรับงานเฉพาะด้านต่าง ๆ ได้อย่างมีประสิทธิภาพ ในงานจำแนกข้อความ โมเดลจะใช้โทเคนพิเศษ [CLS] แทนลำดับข้อความทั้งหมด โดยผลลัพธ์จากตำแหน่งนี้ในเลเยอร์ encoder สุดท้ายจะถูกส่งผ่านไปยังชั้น fully-connected และ softmax เพื่อใช้ในการจำแนกประเภท ข้อมูลนำเข้าในแต่ละโทเคนจะถูกแปลงเป็นเวกเตอร์ด้วยการรวมกันของ token embedding, segment embedding และ position embedding (Zhengjie Gao, Ao Feng, Xinyu Song, and Xi Wu, 2019)



ภาพที่ 2.4 แสดงสถาปัตยกรรมของโมเดล BERTbase-uncase

สำหรับการตั้งค่าพื้นฐานของ BERT ที่เรียกว่า BERTbase โมเดลประกอบด้วย 12 Transformer blocks ขนาดของ hidden layer เท่ากับ 768 มีจำนวน self-attention heads ทั้งหมด 12 หัว และมีจำนวนพารามิเตอร์รวมทั้งหมดประมาณ 110 ล้านพารามิเตอร์ ซึ่งทำให้โมเดลมีความสามารถสูงในการเข้าใจความหมายและบริบทในระดับลึกของภาษา

2.2 งานวิจัยที่เกี่ยวข้อง

งานวิจัยด้าน ABSA ได้พัฒนาไปอย่างต่อเนื่อง โดยมีการประยุกต์ใช้โมเดลจากยุคต่าง ๆ เพื่อเพิ่มความแม่นยำและความสามารถในการจับความซับซ้อนของภาษา

2.2.1 การวิเคราะห์ความรู้สึกเชิงแง่มุมด้วย TF-IDF และ SVM

งานวิจัยของ Hidayati et al. (2021) ได้นำเสนอการประยุกต์ใช้เทคนิค TF-IDF ร่วมกับ Support Vector Machine (SVM) ในการวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) จากรีวิวผลิตภัณฑ์ความงามบนเว็บไซต์ Female Daily โดย TF-IDF ถูกใช้ร่วมกับ word N-gram (ทั้ง unigram และ bigram) เพื่อแปลงข้อความเป็นเวกเตอร์คุณลักษณะเชิงถ่วงน้ำหนัก ซึ่งสามารถเน้นคำที่มีนัยสำคัญต่อความรู้สึกและแง่มุม จากนั้นอัลกอริทึม SVM ซึ่งเหมาะกับการจัดการข้อมูลมิติสูงได้ถูกนำมาใช้ในการจำแนกความคิดเห็นในแต่ละแง่มุม โดยเลือกใช้ kernel แบบเชิงเส้น (linear kernel) ที่ให้ความแม่นยำสูงสุด ผลการทดลองพบว่า preprocessing มีผลอย่างมีนัยสำคัญ โดยเฉพาะขั้นตอนการทำ stemming การลบ stopword และการเลือกใช้ word N-gram โดย word unigram ให้ผลลัพธ์แม่นยำกว่าการใช้ bigram ความแม่นยำสูงสุดของระบบอยู่ที่ 88.35% และยังมีการสร้างพจนานุกรมคำใหม่ทั้งในกลุ่มคำปกติและคำที่ไม่มีความหมายเพิ่มเติม เพื่อปรับปรุงความครอบคลุมของการแปลงข้อความ งานวิจัยนี้จึงสะท้อนให้เห็นถึงประสิทธิภาพของการใช้เทคนิคแบบดั้งเดิมที่มีการปรับจูนอย่างเหมาะสม ทั้งในด้านการสกัดคุณลักษณะ การเลือก representation และการออกแบบกระบวนการก่อนการเรียนรู้ ซึ่งส่งผลให้โมเดลสามารถจัดการกับข้อมูลที่หลากหลายและมีมิติสูงในงาน ABSA ได้อย่างมีประสิทธิภาพ

2.2.2 การวิเคราะห์ความรู้สึกเชิงแง่มุมด้วย Word2vec และ LSTM

งานวิจัยของ Wang et al. (2018) ได้นำเสนอแนวทางใหม่ในการวิเคราะห์ความรู้สึกของข้อความสั้น (short-text sentiment classification) โดยใช้โมเดล Word2Vec ร่วมกับ Long Short-Term Memory (LSTM) ซึ่งแสดงให้เห็นถึงศักยภาพของการผสมผสานคุณลักษณะของเวกเตอร์ฝังตัวคำ (word embeddings) เข้ากับความสามารถของ LSTM ในการจับลำดับของบริบทในข้อความแบบลำดับเวลา (sequential dependency). โมเดล Word2Vec ถูกนำมาใช้เพื่อแปลงคำแต่ละคำให้เป็นเวกเตอร์ตัวเลขที่สะท้อนถึงบริบทของคำนั้นในข้อมูลการฝึก จากนั้น LSTM ถูกใช้ในการเรียนรู้ลำดับของคำเพื่อจับความสัมพันธ์ระยะยาวและการเปลี่ยนแปลงของอารมณ์ในข้อความ การทดลองเปรียบเทียบกับ Naïve Bayes และ Extreme Learning Machine พบว่า LSTM ที่ฝึกด้วยเวกเตอร์จาก Word2Vec สามารถให้ผลลัพธ์ที่ดีกว่าในหลายชุดข้อมูล โดยเฉพาะเมื่อ

มีข้อมูลการฝึกเพียงพอ งานวิจัยนี้จึงยืนยันถึงความเหมาะสมของการใช้ Word2Vec และ LSTM ในการวิเคราะห์ข้อความสั้น ซึ่งมีข้อจำกัดด้านความหลากหลายของคุณลักษณะ

2.2.3 การวิเคราะห์ความรู้สึกเชิงแง่มุมด้วย Fine-tuned BERT

งานวิจัยของ Hoang, Bihorac and Rouces (2019) ได้นำเสนอแนวทางการประยุกต์ใช้โมเดล BERT (Bidirectional Encoder Representations from Transformers) สำหรับการวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) โดยชี้ให้เห็นว่าโมเดล BERT ที่ผ่านการฝึกบนคลังข้อมูลขนาดใหญ่สามารถถูกปรับแต่ง (fine-tuning) อย่างมีประสิทธิภาพสำหรับงาน ABSA โดยไม่ต้องพึ่งพาการออกแบบคุณลักษณะเฉพาะทางหรือการฝังคำแบบดั้งเดิม เช่น Word2Vec หรือ GloVe ผู้วิจัยเสนอวิธีการต่อชั้นจำแนกประเภทอย่างง่ายเข้ากับตำแหน่ง [CLS] ของ BERT เพื่อคาดการณ์อารมณ์ของแง่มุมที่ระบุ ซึ่งสามารถนำไปใช้ได้กับทั้ง Aspect Term และ Aspect Category ได้โดยตรง ผลการทดลองบนชุดข้อมูลมาตรฐานจาก SemEval 2015 และ 2016 แสดงให้เห็นว่าโมเดล BERT ที่ถูกปรับแต่งสามารถให้ผลลัพธ์ที่เหนือกว่าระบบเดิมทุกระบบที่มีอยู่ในขณะนั้น ทั้งในแง่ของความแม่นยำและความสามารถในการเข้าใจบริบทของข้อความในโดเมนร้านอาหาร งานวิจัยนี้จึงยืนยันถึงศักยภาพของ BERT ในการยกระดับประสิทธิภาพของระบบ ABSA ได้อย่างชัดเจน

บทที่ 3

วิธีการวิจัย

บทนี้จะนำเสนอภาพรวมของวิธีการวิจัยที่ใช้ในการพัฒนาและวิเคราะห์โมเดล ABSA รวมถึงรายละเอียดเฉพาะของการเตรียมข้อมูลและการประยุกต์ใช้เทคนิคต่าง ๆ

3.1. ภาพรวมของโครงการ

โครงการนี้มุ่งเน้นการพัฒนากระบวนการวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) สำหรับข้อมูลรีวิวร้านอาหาร โดยมีเป้าหมายหลักคือการระบุแง่มุมที่กล่าวถึงในรีวิว (Aspect Classification) และวิเคราะห์ความรู้สึก (Sentiment Classification) ที่มีต่อแง่มุมเหล่านั้น การดำเนินการวิจัยนี้ครอบคลุมตั้งแต่การเตรียมข้อมูล การสร้างและฝึกฝนโมเดลด้วยเทคนิคต่าง ๆ รวมถึงการนำเสนอผลลัพธ์ผ่านเว็บแอปพลิเคชันอย่างง่าย

3.2 การวิเคราะห์ขอบเขตและความต้องการของระบบ ระบบที่พัฒนาขึ้นมีขอบเขตในการดำเนินการ

ไม่สามารถฝึกโมเดลฝังเวกเตอร์คำ (Word2Vec) และโมเดลภาษาขนาดใหญ่ (BERT) ด้วยตนเองจากข้อมูลต้นฉบับได้ เนื่องจากข้อจำกัดด้านทรัพยากรคอมพิวเตอร์ เวลา และขนาดของชุดข้อมูลที่ใช้ในการฝึกโมเดลขนาดใหญ่ จึงใช้โมเดล Word2Vec ที่ผ่านการฝึกไว้ล่วงหน้าและ BERT ที่ได้รับการ fine-tune มาใช้แทนการฝึกด้วยตนเอง

3.3 การดำเนินงาน

3.3.1 การรวบรวมและเตรียมข้อมูล

ชุดข้อมูลที่ใช้ในการวิจัยนี้คือชุดข้อมูลรีวิวร้านอาหารจาก SemEval โดยมีจำนวน 2853 แถว ซึ่งประกอบด้วยข้อความรีวิวพร้อมกับการระบุแง่มุมและความรู้สึกที่เกี่ยวข้อง ขั้นตอนการเตรียมข้อมูลประกอบด้วย

- การโหลดข้อมูล: SemEval Restaurant14
- แยกแง่มุมและความรู้สึก: จัดการข้อมูลรีวิวแต่ละรายการให้เหลือข้อมูลข้อความรีวิว หมวดหมู่แง่มุม (ที่มีทั้งหมด 5 แ่ง่มุม) พร้อมกับความรู้สึก (Polarity) ของแต่ละแง่มุม

- ข้อความจะถูกทำความสะอาดโดยการแปลงเป็นตัวพิมพ์เล็ก, ลบ URL, ลบ อักขระพิเศษและตัวเลข, และลบช่องว่างเกิน
- การจัดการ 'noaspectterm': สำหรับบางรีวิวที่ไม่มีการระบุ Aspect Term เฉพาะเจาะจง ('noaspectterm') จะยังคงเก็บข้อมูล Category Polarity ไว้เพื่อใช้ในการจำแนกความรู้สึกระดับหมวดหมู่
- การแบ่งชุดข้อมูล: แบ่งข้อมูลออกเป็นชุดฝึก (Training Set), ชุดตรวจสอบ (Validation Set) และชุดทดสอบ (Test Set) ในอัตราส่วน 70% (ฝึก), 15% (ทดสอบ) และ 15% (ตรวจสอบ) ตามลำดับ โดยใช้ Stratified Sampling เพื่อรักษาสัดส่วนของแต่ละคลาส

3.3.2 การสร้างและฝึกฝนโมเดล

- TF-IDF (Term Frequency-Inverse Document Frequency) สำหรับ SVM:
 - วัตถุประสงค์: TF-IDF เป็นเทคนิคการแปลงข้อความเป็นเวกเตอร์ตัวเลขที่สะท้อนความสำคัญของคำในเอกสารเมื่อเทียบกับชุดเอกสารทั้งหมด
 - วิธีการ: ข้อความรีวิวแต่ละข้อความจะถูกแปลงเป็นเวกเตอร์ TF-IDF โดย TfidfVectorizer ซึ่งถูก fit กับข้อมูลข้อความทั้งหมดโดยมีพารามิเตอร์ min_df=2, max_df=0.99, max_features=10000, ngram_range=(1,3) คำที่มีความถี่สูงในเอกสารหนึ่งแต่มีความถี่ต่ำในเอกสารอื่น ๆ จะมีค่า TF-IDF สูง ซึ่งบ่งชี้ว่าเป็นคำที่สำคัญและโดดเด่นในเอกสารนั้น ๆ
 - การใช้งาน: เวกเตอร์ TF-IDF ที่ได้จะถูกใช้เป็นคุณลักษณะ (features) สำหรับฝึกโมเดล SVM ในงาน Aspect Classification และ Sentiment Classification
 - MultiLabelBinarizer: ใช้เพื่อแปลงรายการของแง่มุมสำหรับแต่ละรีวิวให้อยู่ในรูปแบบ Binary (0/1) ซึ่งเป็น Vector Representation ที่แต่ละตำแหน่งของเวกเตอร์จะแทนแง่มุมหนึ่งๆ (เช่น [0, 1, 0, 1, 0] คือมีแง่มุมที่ 2 และ 4)
 - OneVsRestClassifier: ใช้ในการแปลงปัญหา Multi-label Classification ให้เป็นชุดของปัญหา Binary Classification โดยการฝึกโมเดล Binary Classifier หนึ่งตัวสำหรับแต่ละคลาส (แง่มุม) ที่เป็นไปได้ ตัวอย่างเช่น ถ้ามี 5 แ่งมุม จะมี

การฝึก SVM 5 ตัว โดยแต่ละตัวจะทำนายว่าข้อความนั้นมีแง่มุมนั้น ๆ หรือไม่ (Yes/No)

- Word2Vec Embedding สำหรับ LSTM:
 - วัตถุประสงค์: Word2Vec เป็นเทคนิคการเรียนรู้ Word Embedding ที่แปลงคำให้เป็นเวกเตอร์ตัวเลขที่มีความหมายทางภาษาศาสตร์ (Semantic Meaning) โดยที่คำที่มีความหมายคล้ายกันจะมีเวกเตอร์ที่อยู่ใกล้กันในปริภูมิเวกเตอร์
 - วิธีการ: โครงการนี้ใช้วิธีการโหลด Word2Vec ที่มีการ Pre-train มาแล้ว เช่น "Google News 300 bin" ซึ่งเป็นชุดเวกเตอร์คำที่ได้รับการฝึกฝนจากชุดข้อมูลขนาดใหญ่ ทำให้สามารถจับความสัมพันธ์และความหมายของคำได้ดี
 - การใช้งาน: เวกเตอร์ Word2Vec ของแต่ละคำในข้อความจะถูกนำมาเชื่อมต่อกัน (concatenation) เพื่อสร้างเป็นลำดับของเวกเตอร์ ซึ่งจะถูกป้อนเข้าสู่โมเดล LSTM เนื่องจาก LSTM เป็นโมเดลที่เหมาะสมกับการประมวลผลข้อมูลที่เป็นลำดับ (sequential data)
- BERT:
 - สถาปัตยกรรม: โมเดล BERTClass ถูกสร้างขึ้นโดยใช้ BertModel.from_pretrained('bert-base-uncased') เป็นส่วนหลัก จากนั้นเชื่อมต่อกับ Dropout Layer และ Linear Layer
 - Output Layer:
 - สำหรับ Aspect Classification: Linear Layer มี Output ขนาด 5 (ambience, anecdotes/miscellaneous, food, price, service)
 - สำหรับ Sentiment Classification: Linear Layer มี Output ขนาด 3 (negative, neutral, positive)
 - ฟังก์ชัน Loss:
 - สำหรับ Aspect Classification (Multi-label): ใช้ BCEWithLogitsLoss ซึ่งรวม Sigmoid และ Binary Cross Entropy Loss ไว้ด้วยกัน

- สำหรับ Sentiment Classification (Multi-class): ใช้ CrossEntropyLoss
 - Optimizer: ใช้ AdamW ซึ่งเป็น Optimizer ที่นิยมสำหรับโมเดล Transformer
 - Scheduler: ใช้ get_linear_schedule_with_warmup เพื่อปรับ Learning Rate ระหว่างการฝึก
- การจัดการ Multi-label Classification โดยธรรมชาติ (สำหรับ Aspect Classification):
- ในโมเดล BERT ที่ใช้สำหรับ Multi-label Aspect Classification, Output Layer (self.linear) จะมีจำนวนโหนดเท่ากับจำนวนคลาสของแง่มุม (เช่น 5 โหนดสำหรับ 5 แง่มุม)
 - โมเดลจะให้ค่า Logits สำหรับแต่ละแง่มุม และจะตามด้วยฟังก์ชัน torch.sigmoid() เพื่อแปลงค่า Logits เหล่านั้นให้เป็นความน่าจะเป็นระหว่าง 0 ถึง 1 สำหรับแต่ละแง่มุมอย่างอิสระ
 - จากนั้นจึงใช้ BCEWithLogitsLoss ซึ่งเป็นการรวมฟังก์ชัน Sigmoid และ Binary Cross-Entropy Loss เข้าไว้ด้วยกัน ทำให้สามารถคำนวณ Loss สำหรับแต่ละ Label ได้อย่างอิสระ
 - ในการทำนายผล (prediction) ก็จะใช้ Threshold (เช่น 0.5) เพื่อตัดสินใจว่าแง่มุมนั้นๆ มีอยู่ในข้อความหรือไม่ ซึ่งแตกต่างจาก OneVsRestClassifier ที่สร้างโมเดลย่อยหลายตัว BERT สามารถทำนายได้ในรอบเดียว
- สถาปัตยกรรมแบบ End-to-End:
- BERT เป็นสถาปัตยกรรมแบบ End-to-End ซึ่งหมายความว่ามันสามารถรับ Raw Text และเรียนรู้การจำแนกประเภทได้โดยตรง ไม่เหมือน SVM ที่ต้องการคุณลักษณะที่สกัดออกมาแล้ว (เช่น TF-IDF) หรือ LSTM ที่ต้องการ Word Embeddings ที่สร้างไว้ล่วงหน้า
 - กระบวนการ Tokenization ของ BERT (BertTokenizer) จะเตรียม Input IDs, Attention Masks และ Token Type IDs ซึ่งเป็นรูปแบบที่เหมาะสม

สำหรับโมเดล Transformer อยู่แล้ว ไม่จำเป็นต้องใช้ MultiLabelBinarizer
ในขั้นตอนการเตรียม Input สำหรับ BERT

Training Loop:

- โมเดลถูกฝึกฝนเป็นเวลา 10 Epochs
- มีการตรวจสอบ Accuracy และ Loss ทั้งบนชุดฝึกและชุดตรวจสอบในแต่ละ Epoch
- บันทึกโมเดลที่มี Validation Accuracy สูงสุด ("MLTC_model_state.bin" สำหรับ Aspect และ "Sentiment_model_state.bin" สำหรับ Sentiment)

3.4 การประเมินผลโมเดล

Accuracy: เนื่องจาก Accuracy เป็นตัวชี้วัดพื้นฐานและเข้าใจง่าย

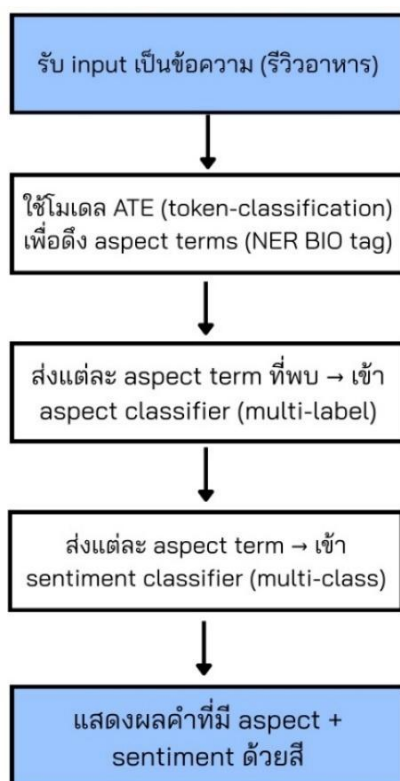
F1-Score: เมื่อชุดข้อมูลมีความไม่สมดุล คือมีตัวอย่างของคลาสหนึ่งมากกว่าอีกคลาสมาก โมเดลอาจทำนายคลาสที่พบบ่อยได้ถูกต้องบ่อยครั้ง ทำให้ค่าความแม่นยำสูงโดยไม่สะท้อนถึงประสิทธิภาพที่แท้จริงของโมเดล โดยเฉพาะกับคลาสที่พบน้อย ในกรณีนี้จึงนิยมใช้ F1-score เป็นตัวชี้วัดหลัก เนื่องจาก F1-score พิจารณาทั้ง precision ความแม่นยำของผลลัพธ์ที่โมเดลทำนายว่าเป็นคลาสเป้าหมาย และ recall ความสามารถในการจับคลาสเป้าหมายทั้งหมดได้ครบถ้วน (Uddagiri Sirisha, 2022)

3.5 การนำเสนอการแสดงผลด้วยสี

ผลลัพธ์การวิเคราะห์ความรู้สึกเชิงแง่มุมและแสดงผลด้วยสีจะถูกนำเสนอผ่านเว็บแอปพลิเคชันที่สร้างด้วย Flask API และ HTML

- Flask API: สร้าง Flask Application เพื่อรับข้อความรีวิวจากผู้ใช้
- การประมวลผลข้อความ: เมื่อได้รับข้อความ โมเดล Aspect Term Extraction (ATE) จาก Hugging Face (gauneg/roberta-base-absa-ate-sentiment) จะถูกใช้เพื่อระบุ Aspect Term ในข้อความ จากนั้น แต่ละ Aspect Term จะถูกส่งเข้าโมเดล Aspect Classification และ Sentiment Classification ที่ฝึกไว้
- การแสดงผล HTML: ข้อความรีวิวต้นฉบับจะถูกนำมาแสดงผลใหม่ในรูปแบบ HTML โดยมีการไฮไลต์คำที่เป็น Aspect Term ด้วยสีที่

แตกต่างกันตาม Sentiment (สีแดงสำหรับ Negative, สีส้มสำหรับ Neutral และสีเขียวสำหรับ Positive) นอกจากนี้ยังแสดงตารางสรุปผลลัพธ์สำหรับแต่ละ Aspect Term ที่ตรวจพบ พร้อมระบุแง่มุมและความรู้สึกที่เกี่ยวข้อง



3.1 pipeline การนำเสนอการแสดงผลด้วยสี

บทที่ 4

ผลการดำเนินงาน

4.1 ผลการทดลอง

ตารางที่ 4.3 ผลการทดลอง aspect classification

Sentiment analysis	TF-IDF + SVM (Accuracy/F1-score)	Word2vec + LSTM (Accuracy/F1-Score)	Fine-tuned BERT (Accuracy/F1-score)
Ambience	0.66 / 0.67	0.80 / 0.78	0.86 / 0.81
Anecdotes/miscellaneous	0.71 / 0.82	0.80 / 0.82	0.84 / 0.81
Food	0.85 / 0.79	0.89 / 0.85	0.91 / 0.93
Price	0.84 / 0.72	0.82 / 0.79	0.85 / 0.86
Service	0.80 / 0.77	0.83 / 0.80	0.88 / 0.87

ตารางที่ 4.4 ผลการทดลอง sentiment classification

Sentiment analysis	TF-IDF + SVM (Accuracy/F1-score)	Word2vec + LSTM (Accuracy/F1-Score)	Fine-tuned BERT (Accuracy/F1-score)
Negative	0.72 / 0.63	0.82 / 0.79	0.86 / 0.82
Neutral	0.63 / 0.57	0.75 / 0.75	0.80 / 0.80
Positive	0.77 / 0.85	0.83 / 0.82	0.89 / 0.89

Aspect-Sentiment Classification

Enter Sentence:

Analyze

Analysis Result:

Sentence with Aspect Sentiments:

The **pizza** was excellent, the **lighting** was perfect, but the **noise** from the **kitchen** was distracting.

Predicted Aspects and Sentiments:

lighting → Aspect(s): ['ambience'], Sentiment: positive
kitchen → Aspect(s): ['ambience'], Sentiment: negative
noise → Aspect(s): ['ambience'], Sentiment: negative
pizza → Aspect(s): ['food'], Sentiment: positive

ภาพที่ 4.1 UI ของ หน้าแสดงผลลัพธ์การแสดงผลด้วยสี

<pre>text = "The dishes were incredibly flavorful, but I felt the cost was a bit steep." full_absa_pipeline(text, tokenizer, aspect_model, sentiment_model, device)</pre>	
<pre>Term: dishes → Aspect(s): food Sentiment: positive Term: cost → Aspect(s): price Sentiment: negative</pre>	
The dishes were incredibly flavorful, but I felt the cost was a bit steep.	
<pre>text = "The pizza was excellent, the lighting was perfect, but the noise from the kitchen was distracting." full_absa_pipeline(text, tokenizer, aspect_model, sentiment_model, device)</pre>	
<pre>Term: noise → Aspect(s): ambience Sentiment: negative Term: kitchen → Aspect(s): ambience Sentiment: negative Term: lighting → Aspect(s): ambience Sentiment: positive Term: pizza → Aspect(s): food Sentiment: positive</pre>	
The pizza was excellent, the lighting was perfect, but the noise from the kitchen was distracting.	
<pre>text = "Even though the food wasn't perfect, the decor was trendy, the music was too loud, staff were inattentive" full_absa_pipeline(text, tokenizer, aspect_model, sentiment_model, device)</pre>	
<pre>Term: food → Aspect(s): food Sentiment: negative Term: decor → Aspect(s): ambience Sentiment: positive Term: music → Aspect(s): ambience Sentiment: negative Term: staff → Aspect(s): ambience, service Sentiment: negative</pre>	
Even though the food wasn't perfect, the decor was trendy, the music was too loud, staff were inattentive	
<pre>text = "Food was still warm when it arrived, so the delivery must have been fast." full_absa_pipeline(text, tokenizer, aspect_model, sentiment_model, device)</pre>	
<pre>Term: delivery → Aspect(s): service Sentiment: positive Term: Food → Aspect(s): food Sentiment: positive</pre>	
Food was still warm when it arrived, so the delivery must have been fast.	

ภาพที่ 4.2 ตัวอย่างการทดลองทดสอบการทำงาน

บทที่ 5

สรุป

5.1. บทสรุป

โครงการนี้มีวัตถุประสงค์เพื่อพัฒนาและเปรียบเทียบประสิทธิภาพของโมเดลการวิเคราะห์ความรู้สึกเชิงแง่มุม (Aspect-Based Sentiment Analysis: ABSA) โดยครอบคลุมการจำแนกแง่มุม (Aspect Classification) และการจำแนกความรู้สึก (Sentiment Classification) ด้วยโมเดลสามประเภท ได้แก่ TF-IDF ร่วมกับ SVM, Word2vec ร่วมกับ LSTM และ Fine-tuned BERT พร้อมนำเสนอผลลัพธ์ด้วยการไฮไลต์รหัสสี เพื่อให้ผู้ใช้งานสามารถตีความผลลัพธ์ได้อย่างชัดเจนและเป็นมิตรต่อการใช้งาน

ผลการทดลองแสดงให้เห็นว่าโมเดล BERT ที่ผ่านกระบวนการ fine-tune มีประสิทธิภาพสูงที่สุด ทั้งในแง่ของความแม่นยำ (Accuracy) และ F1-score ในทั้งสองงาน (Aspect และ Sentiment Classification) โดยเฉพาะอย่างยิ่งในแง่มุม “อาหาร” และ “บริการ” ซึ่งเป็นหมวดหมู่ที่มักปรากฏในรีวิวร้านอาหาร ในขณะที่โมเดล TF-IDF + SVM แม้จะให้ผลลัพธ์ที่เร็วและเบา แต่มีแนวโน้มจะ overfit และให้ประสิทธิภาพต่ำกว่าเมื่อทดสอบกับข้อมูลใหม่ ส่วน Word2vec + LSTM มีความสมดุลและจับบริบทได้ดีในระดับหนึ่ง แต่ยังไม่สามารถเทียบเท่าความสามารถในการเข้าใจบริบทของ BERT ได้ การแสดงผลด้วยรหัสสีช่วยเพิ่มมิติในการตีความผลลัพธ์ โดยสามารถบ่งบอกแง่มุมและอารมณ์ที่สัมพันธ์กันได้อย่างรวดเร็วและเข้าใจง่าย ทำให้โครงการนี้สามารถตอบโจทย์ทั้งในเชิงเทคนิคและการใช้งานจริง และสามารถต่อยอดในการนำไปประยุกต์ใช้ในระบบตรวจสอบความคิดเห็นบนโซเชียลมีเดีย การวิเคราะห์รีวิวสินค้า หรือการปรับปรุงประสบการณ์ลูกค้าในภาคธุรกิจต่อไป

5.2 ข้อจำกัดของการวิจัย

- การมีชุดข้อมูลที่ติดป้ายกำกับน้อย อาจทำให้โมเดลไม่สามารถเรียนรู้ความหลากหลายของข้อความได้อย่างครอบคลุม
- ความหลากหลายของภาษาธรรมชาติ เพราะลักษณะการใช้คำที่หลากหลาย เช่น สำนวน คำสแลง หรือการเขียนที่ไม่เป็นทางการ ยังคงเป็นความท้าทายที่อาจทำให้ระบบไม่สามารถประมวลผลได้อย่างเต็มที่

5.3 ข้อเสนอแนะสำหรับงานวิจัยในอนาคต

- การเพิ่มชุดข้อมูล ควรเพิ่มชุดข้อมูลรีวิวให้มีครอบคลุมในแต่ละคลาส
- พัฒนาโมเดลที่ตอบสนองต่อบริบทได้ดีขึ้น ทดลองใช้โมเดล NLP ขั้นสูง เช่น GPT หรือ RoBERTa ที่สามารถประมวลผลคำและบริบทได้อย่างละเอียดกว่า BERT และ Word2Vec เพื่อปรับปรุงความแม่นยำในการวิเคราะห์
- การปรับปรุงระบบแยกแยะมุมมอง พัฒนาโมเดลที่สามารถระบุแง่มุมใหม่ ๆ โดยไม่ต้องมีการกำหนด aspect ล่วงหน้า
- การพัฒนาโมเดล Term Extraction เพื่อใช้ร่วมกับโมเดล Classification

รายการอ้างอิง

- Attention-based LSTM for Aspect-level Sentiment Classification – ResearchGate.
https://www.researchgate.net/publication/311990858_Attention-based_LSTM_for_Aspect-level_Sentiment_Classification
- McCully, G. A., Hastings, J. D., Xu, S., & Fortier, A. (2024). Comparing unidirectional, bidirectional, and word2vec models for discovering vulnerabilities in compiled lifted code. *arXiv preprint arXiv:2409.17513*.
<https://arxiv.org/pdf/2409.17513>
- Jayakody, D., Isuranda, K., Malkith, A. V. A., De Silva, N., Ponnampereuma, S. R., Sandamali, G. G. N., & Sudheera, K. L. K. (2024, August). Aspect-based Sentiment Analysis Techniques: A Comparative Study. In *2024 Moratuwa Engineering Research Conference (MERCon)* (pp. 205-210). IEEE.
<https://arxiv.org/html/2407.02834v3>
- Palma, D.D., Bellis, D.D., Servedio, G., Anelli, V.W., Narducci, F., Di Noia, T. (2025). LLaMAs Have Feelings Too: Unveiling Sentiment and Emotion Representations in LLaMA Models Through Probing. *arXiv*, arXiv:2505.16491v1. <https://arxiv.org/html/2505.16491v1>
- Nkhata, G., Anjum, U., & Zhan, J. (2025). Sentiment analysis of movie reviews using bert. *arXiv preprint arXiv:2502.18841*.
<https://arxiv.org/abs/2502.18841>
- Diera, A., Lell, N., Garifullina, A., & Scherp, A. (2023, August). Memorization of named entities in fine-tuned bert models. In *International Cross-Domain Conference for Machine Learning and Knowledge Extraction* (pp. 258-279). Cham: Springer Nature Switzerland.
<https://arxiv.org/html/2212.03749v3>

- Vajjala, S., & Shimangaud, S. (2025). Text Classification in the LLM Era--Where do we stand?. *arXiv preprint arXiv:2502.11830*.
<https://arxiv.org/pdf/2502.11830>
- Albladi, A., Uddin, M. K., Islam, M., & Seals, C. (2025). TWSSenti: A Novel Hybrid Framework for Topic-Wise Sentiment Analysis on Social Media Using Transformer Models. *arXiv arXiv:2504.09896*.
<https://arxiv.org/html/2504.09896v1>
- Larasati, U. I., Muslim, M. A., Arifudin, R., & Alamsyah, A. (2019). Improve the accuracy of support vector machine using chi square statistic and term frequency inverse document frequency on movie review sentiment analysis. *Scientific Journal of Informatics*, 6(1), 138-149.
<https://doi.org/10.15294/sji.v6i1.14244>.
- Li, Z., Larson, S., Leach, K. (2024). Document Type Classification using File Names. *arXiv arXiv:2410.01166v1*. <https://arxiv.org/html/2410.01166v1>
- Karim, A. A. J., Asad, K. H. M., & Azam, A. (2024). Strengthening Fake News Detection: Leveraging SVM and Sophisticated Text Vectorization Techniques. Defying BERT?. *arXiv preprint arXiv:2411.12703*.
<https://arxiv.org/html/2411.12703v1>
- Adamuthe, A.C. (2020), Improved Text Classification using Long Short-Term Memory and Word Embedding Technique. *Int. J. Hybrid Inf. Technol.* 13(1), 19–32. https://gvpress.com/journals/IJHIT/vol13_no1/3.pdf
- Big Data Institute (2021). การค้นหาตัวแทนเชิงความหมายของข้อความ: Word2Vec Word Embedding, Part I. <https://bdi.or.th/big-data-101/word2vec/>
- Tangruamsub, S. Long Short-Term Memory (LSTM). *Medium*.
<https://medium.com/@sinart.t/long-short-term-memory-lstm-e6cb23b494c6>

Keylabs (2024). Support Vector Machines (SVM): Fundamentals and Applications.

<https://keylabs.ai/blog/support-vector-machines-svm-fundamentals-and-applications/>

Analytics Vidhya (2025). Support Vector Machine (SVM).

<https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/>

Comparative Analysis of TF-IDF and Word2Vec in Sentiment Analysis: A Case of Food Reviews - ResearchGate, เข้าถึงเมื่อ พฤษภาคม 24, 2025

https://www.researchgate.net/publication/388323929_Comparative_Analysis_of_TF-IDF_and_Word2Vec_in_Sentiment_Analysis_A_Case_of_Food_Reviews

Das, M., & Alphonse, P. J. A. (2023). A comparative study on tf-idf feature weighting method and its analysis using unstructured dataset. *arXiv preprint arXiv:2308.04037*. <https://arxiv.org/abs/2308.04037>

Rink, L., Meijdam, J., & Graus, D. (2024). Aspect-Based Sentiment Analysis for Open-Ended HR Survey Responses. *arXiv preprint arXiv:2402.04812*. <https://arxiv.org/pdf/2402.04812>

Kashid, D. S., Patil, J. D., Buchade, A., & Patil, J. (2025). Live News Classification Using Naive Bayes Classifier. *Cureus*, 2(1). <https://www.cureusjournals.com/articles/1030-live-news-classification-using-naive-bayes-classifier>

Setiawan, E. I., Tjendika, P., Santoso, J., Ferdinandus, F. X., Gunawan, G., & Fujisawa, K. (2024). Aspect-Based Sentiment Analysis of Healthcare Reviews from Indonesian Hospitals based on Weighted Average Ensemble. *Journal of Applied Data Sciences*, 5(4), 1579–1596. <https://bright-journal.org/Journal/index.php/JADS/article/download/328/256>

- Zainuddin, N., Selamat, A., & Ibrahim, R. (2018). Hybrid sentiment classification on twitter aspect-based sentiment analysis. *Applied Intelligence*, 48, 1218-1232. <https://ijisae.org/index.php/IJISAE/article/view/2619>
- Erkan, A., & Güngör, T. (2025). An Aspect Extraction Framework using Different Embedding Types, Learning Models, and Dependency Structure. *arXiv preprint arXiv:2503.03512*. <https://arxiv.org/html/2503.03512v1>
- Dadgar, S. M. H., Araghi, M. S., & Farahani, M. M. (2016, March). A novel text mining approach based on TF-IDF and Support Vector Machine for news classification. In *2016 IEEE International Conference on Engineering and Technology (ICETECH)* (pp. 112-116). IEEE.
https://www.researchgate.net/publication/364829528_A_novel_text_mining_approach_based_on_TF-IDF_and_Support_Vector_Machine_for_news_classification
- NathanN1111/word2vec-google-news-negative-300-bin - Hugging Face.
<https://huggingface.co/NathanN1111/word2vec-google-news-negative-300-bin>
- MACHINE AND DEEP LEARNING MODELS FOR MULTI- CLASS SENTIMENT CLASSIFICATION. *Journal of Theoretical and Applied Information Technology*. <https://www.jatit.org/volumes/Vol102No22/26Vol102No22.pdf>
- Fine-Tuning BERT for Aspect Extraction in Multi-domain ABSA - Informatica, An International Journal of Computing and Informatics.
<https://www.informatica.si/index.php/informatica/article/download/5217/2512>
- Lin, T., Sun, A., & Wang, Y. (2022, May). Aspect-based sentiment analysis through edu-level attentions. In *Pacific-Asia Conference on Knowledge Discovery and Data Mining* (pp. 156-168). Cham: Springer International Publishing.
<https://arxiv.org/pdf/2202.02535>

- Islam, S. M., & Bhattacharya, S. (2022, April). AR-BERT: Aspect-relation enhanced aspect-level sentiment classification with multi-modal explanations. In *Proceedings of the ACM Web Conference 2022* (pp. 987-998). <https://arxiv.org/pdf/2108.11656>
- RoBERTa vs. BERT: Exploring the Evolution of Transformer Models - DS Stream. <https://www.dsstream.com/post/roberta-vs-bert-exploring-the-evolution-of-transformer-models>
- Using Large Language Models for Data Augmentation in Text Classification Models | International Journal of Computing, <https://computingonline.net/computing/article/view/3886>
- Instruct-DeBERTa: A Hybrid Approach for Aspect-based Sentiment Analysis on Textual Reviews - arXiv, <https://arxiv.org/pdf/2408.13202?>
- Presertsom, P. (2020), สกัดใจความสำคัญของข้อความด้วยเทคนิคการประมวลผลทางภาษาเบื้องต้น: TF-IDF, Part 1. <https://bdi.or.th/big-data-101/tf-idf-1/>
- Vapnik, V. N. (1999). An overview of statistical learning theory. *IEEE transactions on neural networks*, 10(5), 988-999.
- Wang, J. H., Liu, T. W., Luo, X., & Wang, L. (2018, October). An LSTM approach to short text sentiment classification with word embeddings. In *Proceedings of the 30th conference on computational linguistics and speech processing (ROCLING 2018)* (pp. 214-223). <https://aclanthology.org/O18-1021/>
- Gao, Z., Feng, A., Song, X., & Wu, X. (2019). Target-dependent sentiment classification with BERT. *Ieee Access*, 7, 154290-154299. <https://ieeexplore.ieee.org/document/8864964>
- Sirisha, U., & Bolem, S. C. (2022). Aspect based sentiment & emotion analysis with ROBERTa, LSTM. *International Journal of Advanced Computer Science and Applications*, 13(11). <https://doi.org.10.14569/IJACSA.2022.0131189>

Sopuru, J. C., Alubo, A., Iloh, P. C., & Lottu, O. A. (2023). Comparative Analysis of Word2Vec and GloVe with LSTM for Sentiment Analysis: Accuracy and Loss Evaluation on Twitter Data. *Internafional Journal of Social Sciences and Scienfific Studies*, 3(6). <https://ijssass.com/journal/comparative-analysis-of-word2vec-and-glove-with-lstm-for-sentiment-analysis-accuracy-and-loss-evaluation-on-twitter-data/>